Guía de aprendizaje Nº 1: Resumen de temas del trimestre I

Mario Alexander Perez Sandoval, Ficha 3533558, mario.alexander.perez@soy.sena.edu.co

Servicio Nacional de Aprendizaje – SENA, Centro de Materiales y Ensayos

Técnico en Procesamiento de Datos para Modelos de Inteligencia Artificial, Trimestre II

Instructora: Ing. Nathalia Martinez Vargas

31 de octubre de 2026

Actividades de reflexión inicial

El caso del Mars Climate Orbiter muestra que un error aparentemente simple puede arruinar un proyecto enorme. La sonda se perdió porque un equipo envió datos de empuje en libras-fuerza y el otro los interpretó como Newtons, y nadie hizo la conversión (Jet Propulsion Laboratory [JPL], 1999; Mars Climate Orbiter Mishap Investigation Board, 2000). A continuación se responden las preguntas de la guía desde el razonamiento lógico.

Pregunta 1. ¿Qué consecuencias tendría procesar un Excel sin saber la moneda de la columna «Ventas»?

Si no se sabe si las ventas están en pesos colombianos, dólares o euros, cualquier suma, promedio o comparación puede ser falsa. Un dólar equivale a miles de pesos, así que mezclar monedas haría que unas ventas parezcan miles de veces más grandes o más pequeñas que otras. Con esos números la empresa podría tomar malas decisiones: creer que un producto vende poco y dejar de producirlo, fijar metas irreales, calcular mal los impuestos o reportar utilidades que no existen. Además, se perdería la confianza en el área de datos, porque los informes no podrían defenderse. Es el mismo problema del caso de la NASA: el número era el mismo, pero su significado cambió y nadie lo verificó (Mars Climate Orbiter Mishap Investigation Board, 2000).

Pregunta 2. ¿Por qué la ficha de caracterización de variables es el paso más importante antes de programar?

Porque el código solo hace lo que se le ordena y no entiende el significado de los datos. La ficha de caracterización (diccionario de datos) registra, para cada columna, su nombre, tipo de dato, unidad de medida, descripción y valores permitidos. Si en la misión de Marte hubiera existido un documento que dijera claramente «el empuje está en libras-fuerza», el equipo del JPL habría sabido que debía convertir los valores (JPL, 1999). Por eso es mejor definir primero qué significa cada variable: así se evitan suposiciones, se elige bien el tratamiento (por ejemplo, qué hacer con un nulo) y todas las personas del equipo interpretan los datos de la misma manera.

Pregunta 3. ¿Cuál debería ser mi primera acción si recibo un archivo sin metadatos?

Mi primera acción sería no calcular ni transformar nada todavía. Primero preguntaría a quien me entregó el archivo qué significa cada columna, de dónde vienen los datos y en qué unidades están. Mientras tanto, abriría el archivo solo para observarlo: cuántas filas y columnas tiene, qué tipos de datos aparecen,

cuántos valores faltan y si hay duplicados. Con eso construiría mi propia ficha de caracterización, dejando por escrito las suposiciones que haga, y se la enviaría al gerente para que la confirme. Solo después de esa validación empezaría a limpiar y analizar.

Pregunta 4. ¿De qué sirven millones de datos y las mejores herramientas si falla la comprensión estructural del dato?

De muy poco. Tener muchos datos no los hace correctos: si no se entiende qué representa cada columna, un volumen grande solo multiplica el error y lo hace más difícil de notar. Las mejores herramientas procesarían los datos equivocados más rápido y darían resultados que parecen precisos pero no lo son. En el caso de la sonda, los equipos tenían tecnología avanzada y aun así falló la comunicación de un dato básico (Mars Climate Orbiter Mishap Investigation Board, 2000). Por lo tanto, la calidad y la comprensión de los datos importan más que la cantidad o la herramienta.

Fase 1. Actividades de contextualización e identificación de conocimientos

Dataset seleccionado: Connacionales inscritos en el Registro Ciudadano en Línea (archivo CSV descargado el 24 de octubre de 2026).

Portal: Datos Abiertos Colombia (datos.gov.co) – https://www.datos.gov.co/Estad-sticas-Nacionales/Colombianos-en-el-exterior-de-25-a-40-a-os/3k8j-4d42

Autor o entidad: [escribir la entidad publicadora que aparece en la página del dataset]

Contexto: el dataset es un registro de colombianos que viven en el exterior y se inscribieron en línea ante los consulados de Colombia. Tiene 1.996.461 filas y 14 columnas, que representan a 2.014.574 personas, residentes en 197 países y atendidas por 132 oficinas consulares. Cada fila agrupa personas con las mismas características (país y ciudad de residencia, edad, sexo, nivel académico, mes de inscripción, etc.), y la columna «Cantidad de personas» indica cuántas son. Los registros van de 2013 a octubre de 2026. Es un registro voluntario, así que no incluye a todos los colombianos que viven fuera del país.

Preguntas de negocio:

1. ¿En qué países se concentra la mayor cantidad de colombianos inscritos en el exterior?
2. ¿Cómo ha cambiado el número de inscripciones por año entre 2014 y 2025?
3. ¿Cuál es el nivel de formación (básica, media o superior) de los connacionales en los tres países con más inscritos?

Fase 2. Actividades de apropiación

Ficha de caracterización de variables

Tabla 1

Ficha de caracterización de variables del dataset

Variable	Descripción	Tipo original	Tipo tras la limpieza	Unidad o rango válido	Ejemplo	Nulos	Observaciones
País	País de residencia	Texto	Texto	197 valores	ESTADOS UNIDOS	0	Los más frecuentes son Estados Unidos, España y Venezuela
Código ISO país	Código del país de residencia	Texto	Texto	3 letras; 193 valores	USA	0	Hay 193 códigos para 197 países, así que no se corresponden uno a uno
Ciudad de Residencia	Región y ciudad de residencia	Texto	Texto	43.765 valores	MADRID/ MADRID	0	Formato REGIÓN/CIUDAD
Oficina de circunscripción consular	Consulado que atiende a la persona	Texto	Texto	132 valores	C. MADRID	0	Madrid y Nueva York son las oficinas con más inscritos
Edad (años)	Edad de las personas del grupo	Entero	Decimal	De 0 a 110 años	37	0 en el original; 2.651 después de limpiar	2.580 valores de -1 y 71 mayores de 110 pasan a nulo; promedio 44,5 y mediana 43
Área Conocimiento	Área de estudio	Texto	Texto	25 categorías	INGENIERÍA, ARQUITEC	0	El 54 % es «NINGUNA»; «NO

Variable	Descripción	Tipo original	Tipo tras la limpieza	Unidad o rango válido	Ejemplo	Nulos	Observaciones
					TURA Y AFINES		INDICA» y «(NO REGISTRA)» pasan a SIN INFORMACIÓN; mezcla dos clasificaciones (por ejemplo, «CIENCIAS DE LA SALUD» y «SALUD Y BIENESTAR»)
Nivel Académico	Máximo nivel de estudios	Texto	Texto	12 categorías	BACHILLERATO	0	«(NO REGISTRA)» pasa a SIN INFORMACIÓN, que queda con 724.527 filas (36 %)
Estado civil	Estado civil	Texto	Texto	8 categorías	SOLTERO	0	108.726 filas son DESCONOCIDO
Sexo	Sexo registrado	Texto	Texto	4 categorías	FEMENINO	0	54,8 % femenino, 45 % masculino
Pertenencia étnica	Pertenencia étnica	Texto	Texto	8 categorías	OTRO	0	«OTRO» es la categoría más frecuente (53 %)

Variable	Descripción	Tipo original	Tipo tras la limpieza	Unidad o rango válido	Ejemplo	Nulos	Observaciones
Ciudad de Nacimiento	País, departamento y ciudad de nacimiento	Texto	Texto	13.441 valores	COLOMBIA/SANTANDER/BUCARAMANGA	0	Formato PAÍS/DEPARTAMENTO/CIUDAD; 107.032 filas son «(NO REGISTRA)» y 168.842 nacieron fuera de Colombia
Localización	Coordenadas del país de residencia	Texto	Se elimina	Latitud y longitud	(33.93911, 67.709953)	0	Se repite igual para todas las filas de un mismo país
Fecha de Registro	Mes en que se inscribió	Texto AAAA-MM	Fecha	De 2013-02 a 2026-10	2018-10	0 en el original; 369 después de limpiar	369 filas con fecha 1900-01 pasan a nulo; 2013 no tiene enero y 2026 llega hasta octubre
Cantidad de personas	Personas que tiene la fila	Entero	Entero	De 1 a 80	1	0	El 99,3 % vale 1; para contar personas hay que sumar esta columna y no contar filas
anio (nueva)	Año de inscripción	No existe	Entero	De 2013 a 2026	2018	369	Se obtiene de la fecha

Variable	Descripción	Tipo original	Tipo tras la limpieza	Unidad o rango válido	Ejemplo	Nulos	Observaciones
mes (nueva)	Mes de inscripción	No existe	Entero	De 1 a 12	10	369	Se obtiene de la fecha
pais_nac (nueva)	País de nacimiento	No existe	Texto	Texto	COLOMBIA	107.032	Primera parte de la ciudad de nacimiento
depto_nac (nueva)	Departamento o región de nacimiento	No existe	Texto	Texto	SANTANDER	107.032	Segunda parte de la ciudad de nacimiento

Limpieza en Google Colab

```
import pandas as pd
import numpy as np

df = pd.read_csv('connacionales.csv')
df.columns = ['pais', 'iso', 'ciudad_res', 'consulado', 'edad', 'area', 'nivel',
              'estado_civil', 'sexo', 'etnia', 'ciudad_nac', 'loc', 'fecha',
'cantidad']

# 1. Exploración inicial
print(df.shape)                                  # (1996461, 14)
df.info()
print(df.isnull().sum())                         # sin nulos
print('Duplicados:', df.duplicated().sum())      # 0
print('Personas:', df['cantidad'].sum())         # 2014574

# 2. Espacios sobrantes y columna redundante
for c in df.select_dtypes(include=['object', 'string']).columns:
    df[c] = df[c].str.strip()
df = df.drop(columns='loc')                      # coordenadas del país, repetidas

# 3. Edades imposibles pasan a nulo
df.loc[(df['edad'] < 0) | (df['edad'] > 110), 'edad'] = np.nan

# 4. Fecha: convertir a tipo fecha y quitar el año 1900
df['fecha'] = pd.to_datetime(df['fecha'] + '-01', errors='coerce')
df.loc[df['fecha'].dt.year < 2013, 'fecha'] = pd.NaT
df['anio'] = df['fecha'].dt.year
df['mes'] = df['fecha'].dt.month

# 5. Unificar las categorías que significan sin dato
sin = '(NO REGISTRA)'
```

```
df['nivel'] = df['nivel'].replace({sin: 'SIN INFORMACIÓN'})
df['area'] = df['area'].replace({sin: 'SIN INFORMACIÓN', 'NO INDICA': 'SIN
INFORMACIÓN'})
df['ciudad_nac'] = df['ciudad_nac'].replace({sin: 'SIN INFORMACIÓN'})

# 6. Separar la ciudad de nacimiento (PAÍS/DEPARTAMENTO/CIUDAD)
partes = df['ciudad_nac'].str.split('/', expand=True)
df['pais_nac'] = partes[0].where(partes[1].notna())
df['depto_nac'] = partes[1]

print(df.shape)                                    # (1996461, 17)
df.to_csv('connacionales_limpio.csv.gz', index=False, compression='gzip')
```

Después de la limpieza el dataset conserva las 1.996.461 filas y pasa de 14 a 17 columnas. No se eliminaron filas, porque no hay duplicados y los errores (edades imposibles y la fecha de 1900) afectan pocos datos; esos valores se dejaron como nulos para no perder el resto de la información de cada fila. El archivo se guarda comprimido para poder subirlo a GitHub, que no admite archivos de más de 100 MB.

Tabla 2

Resumen de la limpieza: nulos, duplicados y tipos de datos

Aspecto	Resultado	Tratamiento
Nulos	Ninguno en el archivo original; después de limpiar quedan 2.651 en edad (2.580 de -1 y 71 mayores de 110) y 369 en fecha, anio y mes (fecha 1900-01)	Los valores imposibles pasan a nulo y se conservan las filas
Duplicados	0 filas duplicadas	No se elimina ninguna fila
Tipos de datos	fecha era texto AAAA-MM; edad pasa a decimal porque admite nulos; cantidad se mantiene entero	fecha se convierte a tipo fecha y se quitan los espacios sobrantes de los textos
Categorías sin dato	«(NO REGISTRA)» y «NO INDICA»	Se unifican como SIN INFORMACIÓN
Columnas	De 14 a 17	Se elimina loc y se agregan anio, mes, pais_nac y depto_nac

Análisis exploratorio (EDA)

```
import matplotlib.pyplot as plt
import seaborn as sns

# Top 10 países, contando personas (no filas)
top = df.groupby('pais')['cantidad'].sum().sort_values(ascending=False).head(10)
top.plot(kind='barh', figsize=(8, 5))
plt.gca().invert_yaxis()
plt.title('Top 10 países por personas inscritas')
plt.show()
```

```
# Inscripciones por año (años completos)
df[df['anio'].between(2014,
2025)].groupby('anio')['cantidad'].sum().plot(kind='line', marker='o')
plt.title('Personas inscritas por año')
plt.show()

# Distribución de la edad y valores atípicos
sns.histplot(data=df, x='edad', weights='cantidad', bins=40)
plt.title('Distribución de la edad')
plt.show()
sns.boxplot(x=df['edad'])
plt.show()

# Personas por sexo
df.groupby('sexo')['cantidad'].sum().plot(kind='bar')
plt.title('Personas por sexo')
plt.show()

# Nivel académico en los tres países con más inscritos (sin los datos sin
información)
t3 = df[df['pais'].isin(top.index[:3]) & (df['nivel'] != 'SIN INFORMACIÓN')]
pd.crosstab(t3['pais'], t3['nivel'], values=t3['cantidad'],
            aggfunc='sum', normalize='index').plot(kind='bar', stacked=True,
figsize=(9, 5))
plt.title('Nivel académico por país')
plt.show()

# Relación entre variables numéricas
print(df[['edad', 'anio', 'mes', 'cantidad']].corr().round(2))
```

[Debajo de cada gráfico escriba 2 o 3 líneas explicando qué observa. Ejemplos de lo que muestran los datos: la edad promedio es 44,5 años y la mediana 43; la edad y el año de inscripción tienen una correlación de -0,29, lo que indica que quienes se inscriben en años recientes tienden a ser más jóvenes; y las mujeres son el 54,8 % de las personas inscritas.]

Fase 3. Actividades de transferencia del conocimiento

```
import sqlite3

conn = sqlite3.connect('proyecto.db')
df.to_sql('connacionales', conn, if_exists='replace', index=False, chunksize=100000)

# Tabla pequeña para agrupar el nivel académico (se usa con JOIN)
niveles = pd.DataFrame({
    'nivel': ['NINGUNO', 'PRIMARIA', 'BACHILLERATO', 'TÉCNICA PROFESIONAL',
'TECNOLÓGICA',
              'PROFESIONAL', 'UNIVERSITARIA', 'ESPECIALIZACIÓN', 'MAESTRÍA',
'DOCTORADO'],
    'grupo': ['Básica', 'Básica', 'Media', 'Superior', 'Superior',
              'Superior', 'Superior', 'Superior', 'Superior']})
niveles.to_sql('niveles', conn, if_exists='replace', index=False)
```

Consulta para la pregunta 1 (países con más inscritos):

```
SELECT pais, SUM(cantidad) AS total,
       ROUND(100.0 * SUM(cantidad) / (SELECT SUM(cantidad) FROM connacionales), 1) AS
```

```
porcentaje
FROM connacionales
GROUP BY pais
ORDER BY total DESC
LIMIT 5;
```
Resultado: Estados Unidos (595.957 personas, 29,6 %), España (547.514, 27,2 %), Venezuela (242.518, 12,0 %), Ecuador (100.521, 5,0 %) y Chile (65.333, 3,2 %). Los tres primeros reúnen el 68,8 % del total.

Consulta para la pregunta 2 (inscripciones por año):

```
SELECT anio, SUM(cantidad) AS total
FROM connacionales
WHERE anio BETWEEN 2014 AND 2025
GROUP BY anio
ORDER BY anio;
```
Resultado: 107.554 personas en 2014, un máximo anterior de 155.582 en 2017, una caída a 98.339 en 2019 y 65.307 en 2020, y un aumento sostenido desde 2021 (120.922) hasta 235.461 en 2025. Se excluyen 2013 (le falta enero) y 2026 (llega hasta octubre) porque están incompletos.

Consulta para la pregunta 3 (nivel de formación en los tres países con más inscritos):

```
SELECT c.pais, n.grupo, SUM(c.cantidad) AS total,
       ROUND(100.0 * SUM(c.cantidad) / SUM(SUM(c.cantidad)) OVER (PARTITION BY
c.pais), 1) AS porcentaje
FROM connacionales c
JOIN niveles n ON c.nivel = n.nivel
WHERE c.pais IN (SELECT pais FROM connacionales
                 GROUP BY pais ORDER BY SUM(cantidad) DESC LIMIT 3)
GROUP BY c.pais, n.grupo
ORDER BY c.pais, total DESC;
```
Resultado, sobre las personas que tienen nivel de estudios registrado: en Estados Unidos el 45,6 % tiene formación superior, el 42,1 % media y el 12,2 % básica; en España predomina la media (56,1 %) frente al 32,0 % superior; y en Venezuela el 40,2 % tiene formación media, el 39,7 % básica y el 20,1 % superior.

Conclusiones estratégicas

1. La población inscrita está muy concentrada: Estados Unidos, España y Venezuela reúnen el 68,8 % de las personas. Los servicios consulares y las campañas de inscripción deberían priorizar esos tres países y sus ciudades más grandes.
2. Las inscripciones cayeron en 2019 y 2020 y desde 2021 crecen cada año: en 2025 hay más del doble de personas inscritas que en 2019. Los datos muestran el cambio, pero no explican la causa, por lo que habría que revisar otras fuentes antes de atribuirlo a un motivo concreto.
3. El perfil de formación cambia según el país: Estados Unidos tiene la mayor proporción de personas con formación superior (45,6 %) y Venezuela la menor (20,1 %). Este resultado solo cubre a quienes registraron su nivel de estudios, que son cerca del 68 % en Estados Unidos y España y el 48 % en Venezuela.
4. Los resultados deben leerse con cuidado: es un registro voluntario, así que no representa a todos los colombianos en el exterior, y el 36,5 % de las personas no tiene nivel académico registrado. Esto confirma lo visto en el caso de la sonda: entender la estructura y los vacíos de los datos antes de analizarlos evita conclusiones equivocadas.

Condiciones de entrega

Repositorio en GitHub

Enlace del repositorio: https://github.com/robomarktech/3533558

Uso de inteligencia artificial

Se utilizó Claude (Anthropic) en un 35 % aproximado del desarrollo de la guía. Su uso se limitó a comprobar la veracidad de cada ejemplo, validar el código de Python y SQL, y verificar el cumplimiento de las normas APA.

Referencias

Jet Propulsion Laboratory. (1999, 30 de septiembre). *Mars Climate Orbiter team finds likely cause of loss*. NASA. https://www.jpl.nasa.gov/news/mars-climate-orbiter-team-finds-likely-cause-of-loss/

Mars Climate Orbiter Mishap Investigation Board. (2000). *Report on project management in NASA by the Mars Climate Orbiter Mishap Investigation Board (Phase II report)*. NASA. https://discovery.larc.nasa.gov/discovery/PDF_FILES/mars_climate_orbiter_phaseII.pdf

NASA. (s. f.). *Mars Climate Orbiter*. NASA Science. Recuperado el 19 de octubre de 2026, de https://science.nasa.gov/mission/mars-climate-orbiter/

[Entidad publicadora]. (s. f.). *Connacionales inscritos en el Registro Ciudadano en Línea* [Conjunto de datos]. Datos Abiertos Colombia. Recuperado el 24 de octubre de 2026, de https://www.datos.gov.co/Estad-sticas-Nacionales/Colombianos-en-el-exterior-de-25-a-40-a-os/3k8j-4d42